



**ECOLE MAROCAINE DES
SCIENCES DE L'INGENIEUR**
Membre de **HONORIS UNITED UNIVERSITIES**

**École Marocaine des Sciences de l'Ingénieur
Casablanca - Maarif
Filière : Ingénierie Informatique et Réseaux**

Rapport de Projet Machine Learning

Analyse des Facteurs Influençant la Demande de Vélos partagés et Construction de Modèles Prédictifs

Réalisé par :

Hasnaoui Sara
Hajdaoui Sara
Mekkaoui Imane

Encadré par :

M.Sekhara

ANNÉE UNIVERSITAIRE : 2025/2026

Résumé

Ce projet porte sur la prévision de la demande quotidienne de vélos partagés à partir du Bike Sharing Dataset de l'UCI Machine Learning Repository. L'objectif principal est d'identifier les facteurs influençant la demande et de construire un modèle capable d'estimer le nombre de locations journalières.

Une analyse exploratoire a permis d'étudier l'influence des variables météorologiques et calendaires sur la demande. Plusieurs étapes de prétraitement ont ensuite été réalisées, notamment la création de nouvelles variables, la sélection des caractéristiques pertinentes et la mise en place d'un découpage temporel des données afin de reproduire un contexte réel de prédiction.

Quatre modèles de régression ont été entraînés et comparés : la Régression Linéaire, la Régression Ridge, le Random Forest et le Gradient Boosting. Les performances ont été évaluées à l'aide des métriques MAE, RMSE et R^2 .

Les résultats montrent que le modèle Gradient Boosting obtient les meilleures performances avec un coefficient de détermination de 0,6454. L'analyse met également en évidence le rôle majeur de la température, de la température ressentie et des conditions météorologiques dans la prédiction de la demande.

Mots-clés : Machine Learning, Régression, Gradient Boosting, Bike Sharing Dataset, Prévision de la demande, Mobilité urbaine.

Table des matières

Résumé	i
Introduction generale	1
1 Présentation des données	2
1.1 Description du jeu de données	2
1.2 Structure du dataset	2
1.3 Description des variables	2
1.4 Variable cible	3
1.5 Qualité des données	3
1.6 Conclusion	3
2 Analyse exploratoire des données	4
2.1 Introduction	4
2.2 Évolution temporelle de la demande	4
2.3 Analyse de la saisonnalité	5
2.4 Influence de la température et des conditions météorologiques	6
2.5 Analyse des variables calendaires	7
2.6 Analyse des valeurs atypiques	7
2.7 Conclusion	8
3 Prétraitement des données et ingénierie des caractéristiques	9
3.1 Introduction	9
3.2 Création des variables calendaires	9
3.3 Sélection des variables	9
3.4 Prévention de la fuite d'information	10
3.5 Jeu de données final	10
3.6 Découpage temporel des données	10
3.7 Normalisation des données	11
3.8 Conclusion	11
4 Résultats et discussion	12
4.1 Introduction	12

TABLE DES MATIÈRES

4.2	Comparaison des performances des modèles	12
4.3	Analyse des modèles linéaires	12
4.4	Analyse des modèles à base d'arbres	13
4.5	Analyse détaillée du modèle Gradient Boosting	13
4.6	Importance des variables	14
4.7	Discussion	14
4.8	Conclusion	14
5	Conclusion générale et perspectives	15
	Bibliographie	16

Introduction

Les systèmes de vélos en libre-service occupent aujourd’hui une place importante dans les solutions de mobilité urbaine durable. Leur développement permet de réduire la congestion routière, de limiter les émissions polluantes et d’offrir aux citoyens un moyen de transport flexible et écologique. Pour les opérateurs de ces services, la prévision de la demande constitue un enjeu essentiel afin d’assurer une disponibilité optimale des vélos et une gestion efficace des stations.

Dans ce contexte, l’analyse des facteurs influençant la demande de vélos partagés représente une problématique particulièrement intéressante. Les conditions météorologiques, les saisons ainsi que les variables calendaires peuvent avoir un impact significatif sur le nombre de locations enregistrées chaque jour.

L’objectif de ce projet est d’étudier et de prédire la demande quotidienne de vélos à partir du *Bike Sharing Dataset* de l’UCI Machine Learning Repository. Ce jeu de données couvre les années 2011 et 2012 et contient des informations météorologiques, saisonnières et calendaires associées au nombre total de locations journalières.

La démarche adoptée repose d’abord sur une analyse exploratoire des données afin d’identifier les principales tendances et relations entre les variables. Une phase de prétraitement et de création de variables est ensuite réalisée avant l’entraînement de plusieurs modèles de régression : Régression Linéaire, Ridge Regression, Random Forest et Gradient Boosting. Les performances de ces modèles sont comparées à l’aide des métriques MAE, RMSE et (R^2).

Ce rapport présente successivement les données utilisées, la méthodologie mise en œuvre, les résultats obtenus ainsi que leur interprétation, avant de conclure sur les principaux enseignements de cette étude.

Présentation des données

1.1 Description du jeu de données

Les données utilisées proviennent du *Bike Sharing Dataset* de l'*UCI Machine Learning Repository*. Dans cette étude, le fichier `day.csv` a été retenu afin de modéliser la demande quotidienne de vélos partagés. Il couvre la période 2011–2012 et contient 731 observations décrites par 16 variables.

L'objectif est de prédire le nombre total de locations quotidiennes à partir des informations météorologiques et calendaires disponibles.

1.2 Structure du dataset

Le Tableau 1.1 présente les principales caractéristiques du jeu de données étudié.

TABLE 1.1 – Résumé du jeu de données

Caractéristique	Valeur
Source	UCI Bike Sharing Dataset
Fichier utilisé	<code>day.csv</code>
Période couverte	2011–2012
Nombre d'observations	731
Nombre de variables	16
Granularité	Journalière
Variable cible	<code>cnt</code>

1.3 Description des variables

Les principales variables utilisées dans le projet sont présentées dans le Tableau 1.2.

TABLE 1.2 – Description des principales variables

Variable	Description
<code>dteday</code>	Date de l’observation
<code>season</code>	Saison de l’année
<code>yr</code>	Année (2011 ou 2012)
<code>mnth</code>	Mois de l’année
<code>holiday</code>	Indicateur de jour férié
<code>weekday</code>	Jour de la semaine
<code>workingday</code>	Indicateur de jour ouvré
<code>weathersit</code>	Conditions météorologiques
<code>temp</code>	Température normalisée
<code>atemp</code>	Température ressentie normalisée
<code>hum</code>	Humidité relative
<code>windspeed</code>	Vitesse du vent normalisée
<code>casual</code>	Utilisateurs occasionnels
<code>registered</code>	Utilisateurs enregistrés
<code>cnt</code>	Nombre total de locations

1.4 Variable cible

La variable cible est `cnt`, représentant le nombre total de locations quotidiennes :

[`cnt` = `casual` + `registered`]

Les variables `casual` et `registered` ne sont pas utilisées lors de la modélisation afin d’éviter toute fuite d’information.

1.5 Qualité des données

L’analyse du dataset montre l’absence de valeurs manquantes et de doublons. Les types de données sont cohérents et la relation entre `cnt`, `casual` et `registered` est vérifiée pour l’ensemble des observations.

Le jeu de données est donc directement exploitable pour les étapes de prétraitement et de modélisation.

1.6 Conclusion

La demande présente une forte variabilité et est principalement portée par les utilisateurs enregistrés, ce qui justifie la poursuite de l’analyse exploratoire.

Analyse exploratoire des données

2.1 Introduction

L'analyse exploratoire des données vise à identifier les principaux facteurs influençant la demande de vélos partagés et à étudier les relations entre les variables explicatives et la variable cible `cnt`. Cette étape permet également de préparer la phase de modélisation.

2.2 Évolution temporelle de la demande

La Figure 2.1 présente l'évolution quotidienne du nombre total de locations sur l'ensemble de la période étudiée.




FIGURE 2.1 – Évolution temporelle de la demande quotidienne

La série temporelle révèle une hausse progressive de la demande entre 2011 et 2012 ainsi qu'une forte saisonnalité, avec des niveaux de fréquentation plus élevés en été et plus faibles en hiver.

2.3 Analyse de la saisonnalité




FIGURE 2.2 – Distribution de la demande selon les saisons

Les résultats montrent des différences significatives entre les saisons. L'automne et l'été enregistrent les niveaux de fréquentation les plus élevés, tandis que le printemps présente la demande la plus faible. La dispersion observée indique que d'autres facteurs interviennent également dans l'explication de la demande.

2.4 Influence de la température et des conditions météorologiques




FIGURE 2.3 – Relation entre la température, les saisons et la demande

Une relation positive est observée entre la température et le nombre de locations. Le coefficient de corrélation obtenu est :

$$[r = 0.627]$$

Cette valeur confirme que la température constitue l'un des principaux facteurs explicatifs de la demande.

Les corrélations obtenues avec la variable cible sont résumées dans le Tableau 2.1.

TABLE 2.1 – Corrélations entre les variables météorologiques et la demande

Variable	Corrélation avec <code>cnt</code>
Température réelle	0.627
Humidité	-0.101
Vitesse du vent	-0.235
Conditions météorologiques	-0.300

La température présente la corrélation la plus élevée, tandis que l'humidité, le vent et les mauvaises conditions météorologiques ont un impact négatif sur la demande.

2.5 Analyse des variables calendaires




FIGURE 2.4 – Analyse des tendances de la demande

L'analyse met en évidence une augmentation progressive de la demande entre janvier et septembre, suivie d'une diminution en fin d'année. Les jours ouvrés présentent une fréquentation légèrement supérieure aux week-ends et les journées ensoleillées enregistrent les niveaux de demande les plus élevés.

2.6 Analyse des valeurs atypiques

Plusieurs observations atypiques ont été identifiées dans les données. Elles correspondent probablement à des événements particuliers ou à des conditions météorologiques exceptionnelles. Ces valeurs ne sont pas considérées comme des erreurs et apportent une information utile aux modèles prédictifs.

2.7 Conclusion

L'analyse exploratoire met en évidence une forte saisonnalité de la demande ainsi qu'une influence importante des conditions météorologiques. La température apparaît comme la variable la plus corrélée à la demande, tandis que l'humidité et le vent présentent un impact négatif. Ces résultats confirment la pertinence des variables retenues pour la phase de modélisation.

Prétraitement des données et ingénierie des caractéristiques

3.1 Introduction

Cette phase de prétraitement vise à préparer les données pour l'apprentissage automatique en créant de nouvelles variables, en sélectionnant les caractéristiques pertinentes et en mettant en place une stratégie d'évaluation adaptée au caractère temporel du problème.

3.2 Création des variables calendaires

Afin de mieux représenter les variations temporelles de la demande, plusieurs variables ont été créées à partir de `dtoday`. Les variables générées sont présentées dans le Tableau 3.1.

TABLE 3.1 – Variables créées lors du prétraitement	
Variable	Description
heightmois	
Numéro du mois (1 à 12)	
semaine	Numéro de semaine ISO (1 à 53)
$est_{weekend}$	1 si samedi ou dimanche, 0 sinon
periode	Saison sous forme textuelle
$periode_{num}$	Encodage numérique de la saison

Ces variables permettent de prendre en compte les effets liés aux saisons, aux semaines et aux week-ends.

3.3 Sélection des variables

Les variables exclues de la modélisation sont présentées dans le Tableau 3.2.

TABLE 3.2 – Variables exclues de la modélisation

Variable	Justification
instant	Identifiant de ligne sans valeur prédictive
dteday	Date brute déjà représentée par les variables calendaires
cnt	Variable cible
casual	Composante directe de la variable cible
registered	Composante directe de la variable cible
season _{label}	Version textuelle de season
weather _{label}	Version textuelle de weathersit
periode	Version textuelle de periode _{num}
temp _{reel}	Information redondante avec temp

Cette sélection permet de conserver uniquement les informations utiles à la prédiction.

3.4 Prévention de la fuite d’information

Les variables `casual` et `registered` ont été supprimées car elles composent directement la variable cible :

[cnt = casual + registered]

Cette étape garantit une évaluation réaliste des performances des modèles.

3.5 Jeu de données final

Après nettoyage et sélection, le jeu de données final contient 731 observations décrites par 15 variables explicatives.

TABLE 3.3 – Variables retenues pour la modélisation

Variations météorologiques	Variations calendaires	Variations temporelles
temp	mnth	yr
atemp	weekday	mois
hum	holiday	semaine
windspeed	workingday	periode_num
weathersit	est_weekend	season

3.6 Découpage temporel des données

Afin de respecter la nature temporelle du problème, un découpage chronologique a été adopté.




FIGURE 3.1 – Découpage temporel des ensembles d’entraînement et de test

La date de coupure a été fixée au 1^{er} juillet 2012.

TABLE 3.4 – Répartition des ensembles de données

Ensemble	Période	Nombre de jours	Pourcentage
Train	01/01/2011 – 30/06/2012	547	74,8%
Test	01/07/2012 – 31/12/2012	184	25,2%

Ce découpage évite toute fuite temporelle et reproduit les conditions réelles d’un système de prévision.

3.7 Normalisation des données

Une standardisation a été appliquée aux modèles linéaires selon :

$$z = \frac{x - \mu}{\sigma}$$

où x est la valeur initiale, μ la moyenne et σ l’écart-type.

3.8 Conclusion

Cette phase a permis de créer de nouvelles variables, de sélectionner les caractéristiques pertinentes et d’éliminer les risques de fuite d’information. Les données sont désormais prêtes pour l’entraînement et l’évaluation des modèles de régression.

Résultats et discussion

4.1 Introduction

Ce chapitre présente l'évaluation des modèles de régression développés pour la prévision de la demande de vélos partagés. Les performances sont comparées à l'aide des métriques MAE, RMSE et R^2 , puis le modèle le plus performant est analysé plus en détail.

4.2 Comparaison des performances des modèles

Les performances ont été évaluées à l'aide des métriques MAE, RMSE et R^2 . Les résultats obtenus sur l'ensemble de test sont présentés dans le Tableau ??.




FIGURE 4.1 – Comparaison des performances des modèles

Les modèles à base d'arbres obtiennent les meilleures performances. Le Gradient Boosting arrive en première position avec un coefficient R^2 de 0,6454, suivi du Random Forest avec 0,6059. Les modèles linéaires présentent des performances plus limitées.

4.3 Analyse des modèles linéaires

La Régression Linéaire atteint un coefficient R^2 de 0,5624 tandis que la Régression Ridge obtient 0,5686 grâce à la régularisation. Ces modèles capturent les tendances générales mais

restent limités face aux relations non linéaires présentes dans les données.

4.4 Analyse des modèles à base d'arbres

Le Random Forest améliore les résultats avec un coefficient R^2 de 0,6059. Le Gradient Boosting obtient les meilleures performances avec un coefficient R^2 de 0,6454 et un RMSE de 1036,80. Ces résultats confirment l'efficacité des méthodes d'ensemble pour ce problème de prédiction.

4.5 Analyse détaillée du modèle Gradient Boosting




FIGURE 4.2 – Analyse des résidus du modèle Gradient Boosting

L'analyse des résidus montre une répartition globalement centrée autour de zéro, indiquant l'absence de biais majeur. Les valeurs réelles et prédites restent proches, ce qui confirme la capacité du modèle à reproduire les tendances observées.

4.6 Importance des variables




FIGURE 4.3 – Importance des variables dans le modèle Gradient Boosting

La température est la variable la plus influente, suivie de la température ressentie et de l'année. L'humidité, le vent et les conditions météorologiques contribuent également à la prédiction, tandis que les variables calendaires ont un impact plus limité.

4.7 Discussion

Les résultats montrent que les variables météorologiques, en particulier la température, jouent un rôle majeur dans la prévision de la demande. Les performances du Gradient Boosting confirment le caractère non linéaire des relations entre les variables explicatives et la demande.

4.8 Conclusion

Le modèle Gradient Boosting obtient les meilleures performances avec un coefficient R^2 de 0,6454. L'analyse des variables confirme l'importance des facteurs météorologiques dans la prévision de la demande de vélos partagés.

Conclusion générale et perspectives

Ce projet avait pour objectif de prédire la demande quotidienne de vélos partagés à partir de données météorologiques et calendaires issues du Bike Sharing Dataset. Pour atteindre cet objectif, plusieurs étapes ont été réalisées, notamment l'analyse exploratoire des données, le prétraitement, la création de nouvelles variables et l'entraînement de différents modèles de régression.

L'analyse des données a montré que la demande est fortement influencée par les conditions météorologiques, en particulier la température, la température ressentie et les saisons. Les résultats ont également mis en évidence une évolution importante de l'utilisation du service entre 2011 et 2012 ainsi qu'une forte saisonnalité de la demande.

Quatre modèles ont été évalués : la Régression Linéaire, la Régression Ridge, le Random Forest et le Gradient Boosting. Les résultats obtenus montrent que le modèle Gradient Boosting est le plus performant avec un coefficient de détermination R^2 de 0,6454. L'analyse de l'importance des variables confirme que les facteurs climatiques jouent un rôle essentiel dans la prédiction de la demande.

Malgré ces résultats satisfaisants, certaines limites demeurent, notamment la durée relativement courte de la période étudiée et l'absence de certaines variables externes pouvant influencer les comportements des utilisateurs. Dans de futurs travaux, il serait intéressant d'intégrer davantage de données et d'expérimenter des modèles plus avancés tels que XG-Boost ou des réseaux de neurones dédiés aux séries temporelles.

En conclusion, ce projet a permis de mettre en œuvre l'ensemble des étapes d'un processus de Machine Learning appliqué à une problématique réelle de mobilité urbaine et de démontrer l'intérêt des techniques prédictives pour améliorer la gestion des systèmes de vélos partagés.

Bibliographie

1. Fanaee-T, H., Gama, J. (2014). *Bike Sharing Dataset*. UCI Machine Learning Repository. Disponible sur : <https://archive.ics.uci.edu/ml/datasets/Bike+Sharing+Dataset>
2. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., Duchesnay, E. (2011). *Scikit-learn : Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
3. Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. 3rd Edition, O'Reilly Media.
4. Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
5. Friedman, J. H. (2001). *Greedy Function Approximation : A Gradient Boosting Machine*. Annals of Statistics, 29(5), 1189–1232.
6. Hoerl, A. E., Kennard, R. W. (1970). *Ridge Regression : Biased Estimation for Nonorthogonal Problems*. Technometrics, 12(1), 55–67.
7. James, G., Witten, D., Hastie, T., Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.
8. Documentation officielle Scikit-Learn. Disponible sur : <https://scikit-learn.org>
9. Documentation officielle Pandas. Disponible sur : <https://pandas.pydata.org>
10. Documentation officielle Matplotlib. Disponible sur : <https://matplotlib.org>
11. Documentation officielle Seaborn. Disponible sur : <https://seaborn.pydata.org>